

# Aumento de la eficiencia de las redes generativas adversarias mediante el uso de transferencia de conocimiento

**Alumno:** Javier Martí Isasi

**Director:** Dr. Félix José Fuentes Hurtado

**Titulación:** Máster Universitario en Inteligencia Artificial

**Curso académico:** 2020-2021

**Convocatoria:** Tercera



**Universidad**  
Internacional  
de Valencia


1. INTRODUCCIÓN
2. OBJETIVOS
3. ESTADO DEL ARTE
4. MÉTODOS
5. RESULTADOS
6. CONCLUSIONES
7. LÍNEAS FUTURAS

## **1. INTRODUCCIÓN**

- 2. OBJETIVOS
- 3. ESTADO DEL ARTE
- 4. MÉTODOS
- 5. RESULTADOS
- 6. CONCLUSIONES
- 7. LÍNEAS FUTURAS


# Motivación

- Realizar una investigación en el campo de la visión artificial y, en concreto, en las redes generativas.
- Intereses y aficiones personales.



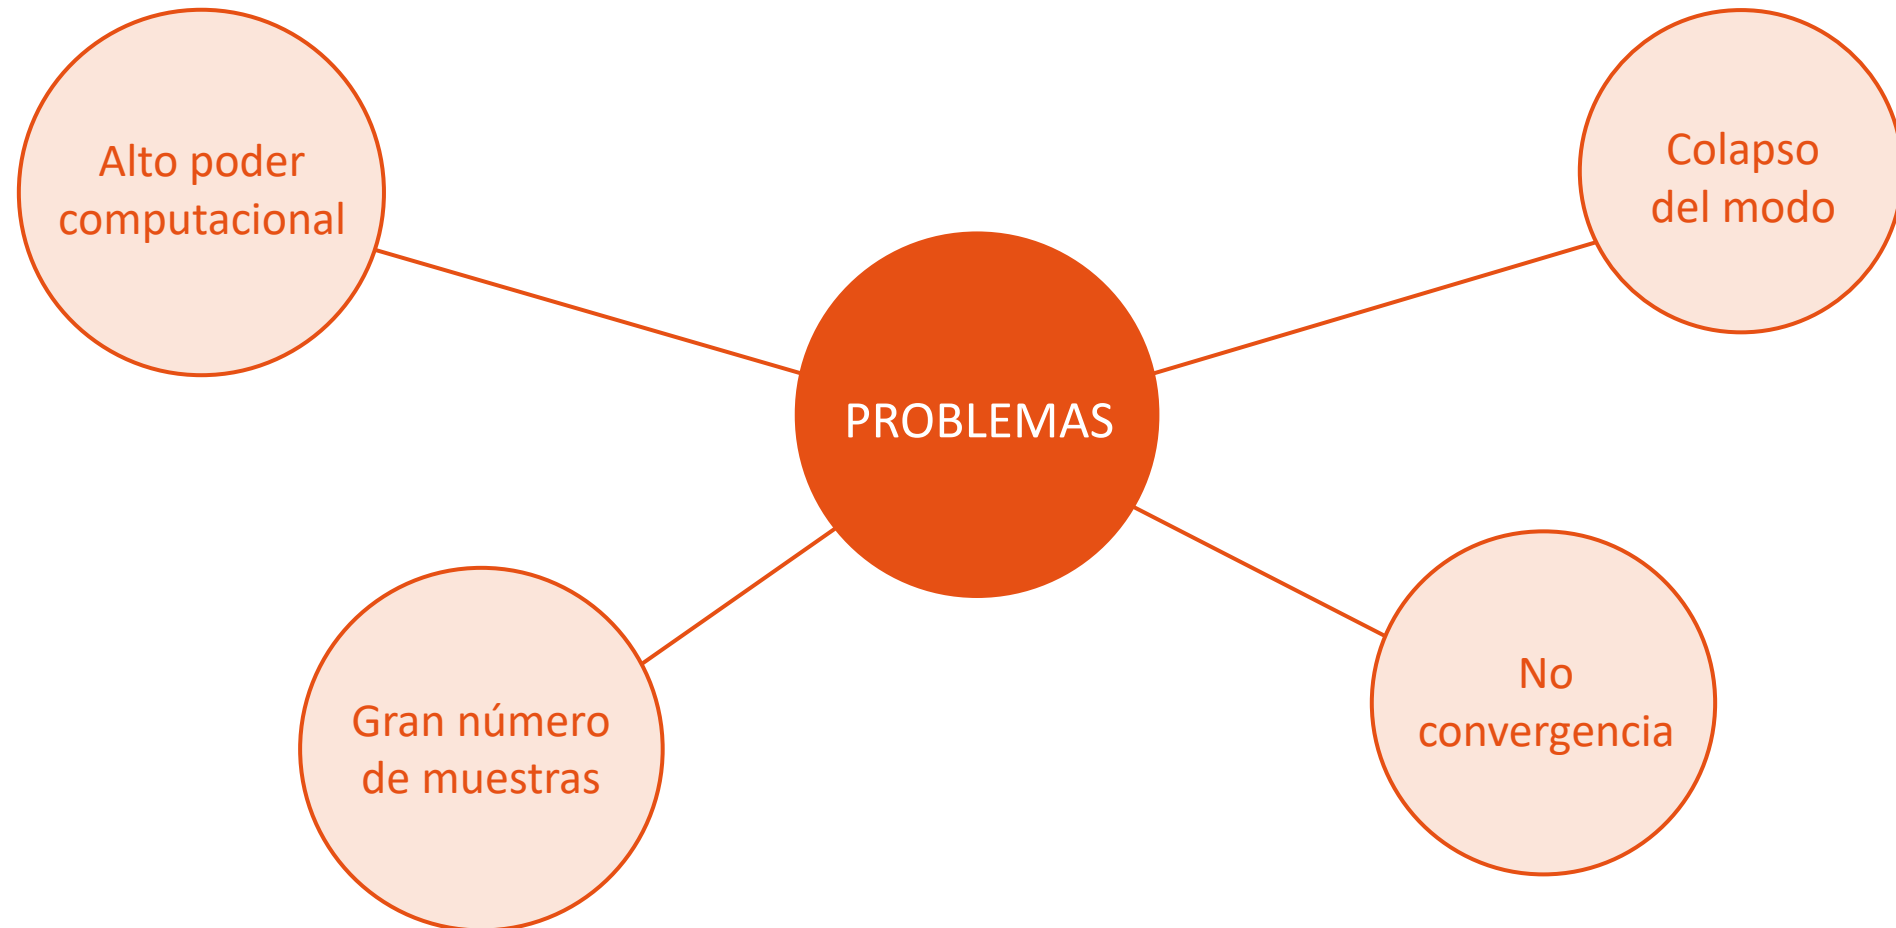
# Redes generativas adversarias (GANs)

- Son modelos generativos englobados dentro del campo de visión artificial.
- Están compuestas por un submodelo generativo  $G$  y un submodelo discriminativo  $D$  que compiten entre sí.
- Sus aplicaciones y rendimiento han experimentado un crecimiento asombroso en los últimos años.



# Problemas comunes de las GANs

---



1. INTRODUCCIÓN

**2. OBJETIVOS**

3. ESTADO DEL ARTE

4. MÉTODOS

5. RESULTADOS

6. CONCLUSIONES

7. LÍNEAS FUTURAS

# Objetivos

---

## OBJETIVO PRINCIPAL

El objetivo principal es aumentar la eficiencia de las GANs, con el fin de obtener imágenes de gran calidad en datasets reducidos y con menores necesidades de computación.

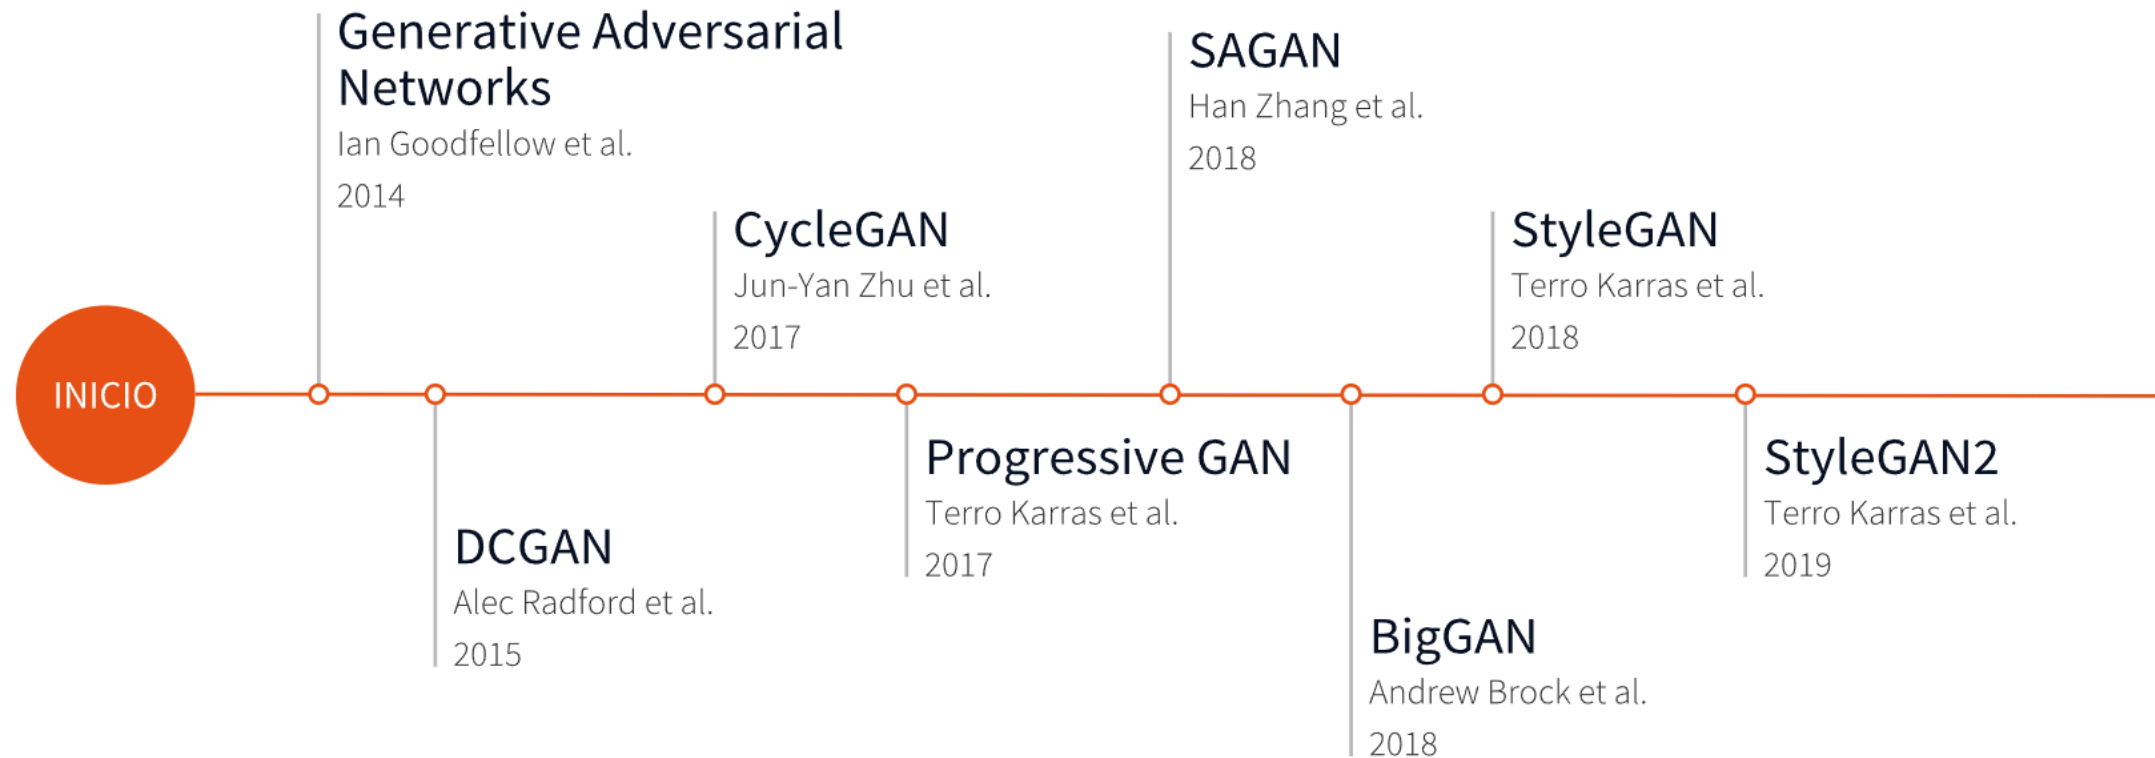
## OBJETIVOS ESPECÍFICOS

- Realizar una investigación exhaustiva del estado del arte de las GANs.
- Estudiar el método de transferencia de conocimiento y ajuste fino.
- Elegir y transformar los distintos datasets.
- Diseñar un modelo que aumente la eficiencia de la red GAN elegida mediante el método de transferencia de conocimiento y ajuste fino.
- Investigar y aplicar otros métodos que ayuden a mejorar la eficiencia de los modelos.



1. INTRODUCCIÓN
2. OBJETIVOS
- 3. ESTADO DEL ARTE**
4. MÉTODOS
5. RESULTADOS
6. CONCLUSIONES
7. LÍNEAS FUTURAS

# Estado del arte - GANs



# Estado del arte - Transferencia de conocimiento



1. INTRODUCCIÓN
2. OBJETIVOS
3. ESTADO DEL ARTE
- 4. MÉTODOS**
5. RESULTADOS
6. CONCLUSIONES
7. LÍNEAS FUTURAS

# Métodos implementados

---



Arquitectura  
GAN

BigGAN



Transferencia de  
conocimiento y  
ajuste fino

MineGAN



Aumento de  
datos

DiffAugment



Técnica de  
regularización

CR

Con la implementación de estos métodos, en este trabajo se aporta:

- Una investigación de las mejoras obtenidas mediante transferencia de conocimiento y ajuste fino.
- Nuevos diseños que combinan el método de transferencia de conocimiento y ajuste fino con los métodos de aumento de datos y técnicas de regularización.

# Arquitectura GAN - BigGAN

---

Brock, A. et al. (2018). *Large Scale GAN Training for High Fidelity Natural Image Synthesis*.



- Incluye una colección de mejores prácticas a través de una amplia gama de extensiones y modelos GAN.
- Utiliza una distribución normal truncada (“truco de truncamiento”).
- Genera imágenes de gran calidad en una amplia gama de clases de objetos.



# Transferencia de conocimiento - MineGAN

Wang, Y. et al. (2019). *MineGAN: effective knowledge transfer from GANs to target domains with few images.*



- Incluye una red minera que identifica qué parte de la distribución generativa produce las muestras más cercanas al dominio objetivo.
- Localiza automáticamente los pesos específicos objetivo.
- Consigue transferir de forma satisfactoria el conocimiento a dominios con pocas imágenes.



# Aumento de datos - DiffAugment

Zhao, S. et al. (2020). *Differentiable Augmentation for Data-Efficient GAN Training*.

- Realiza varios tipos de aumentos de datos tanto en las muestras reales como en las falsas.
- Propaga con éxito los gradientes de las muestras aumentadas a  $G$ .
- Consigue generar imágenes de alta calidad y una estabilización eficaz en datasets reducidos.






# Técnica de regularización - CR

Zhang, H. et al. (2019). *Consistency Regularization for Generative Adversarial Networks*.

- Técnica de regularización de consistencia.
- Aumenta los datos de entrada del discriminador y penaliza la sensibilidad.
- Induce al modelo a producir la misma salida a partir de varios aumentos de datos.
- Funciona eficazmente en varias arquitecturas GAN.



1. INTRODUCCIÓN
2. OBJETIVOS
3. ESTADO DEL ARTE
4. MÉTODOS
- 5. RESULTADOS**
6. CONCLUSIONES
7. LÍNEAS FUTURAS

# Limitaciones de hardware

---

- Las GANs requieren de un gran poder computacional.
- Los entrenamientos han sido realizados mediante una GPU NVIDIA TITAN X de 12Gb.
- El hardware disponible no alcanza los recursos mínimos recomendados para algunos modelos diseñados.




# Conjuntos de datos

## 100-Obama



100 imágenes  
128x128px  
Caras de Obama  
Menor variabilidad

## 1000-LSUN



1000 imágenes  
128x128px  
Dataset LSUN bedroom  
Mayor variabilidad

# Modelos diseñados

## BigGAN

Desde cero

## BigGAN+TC

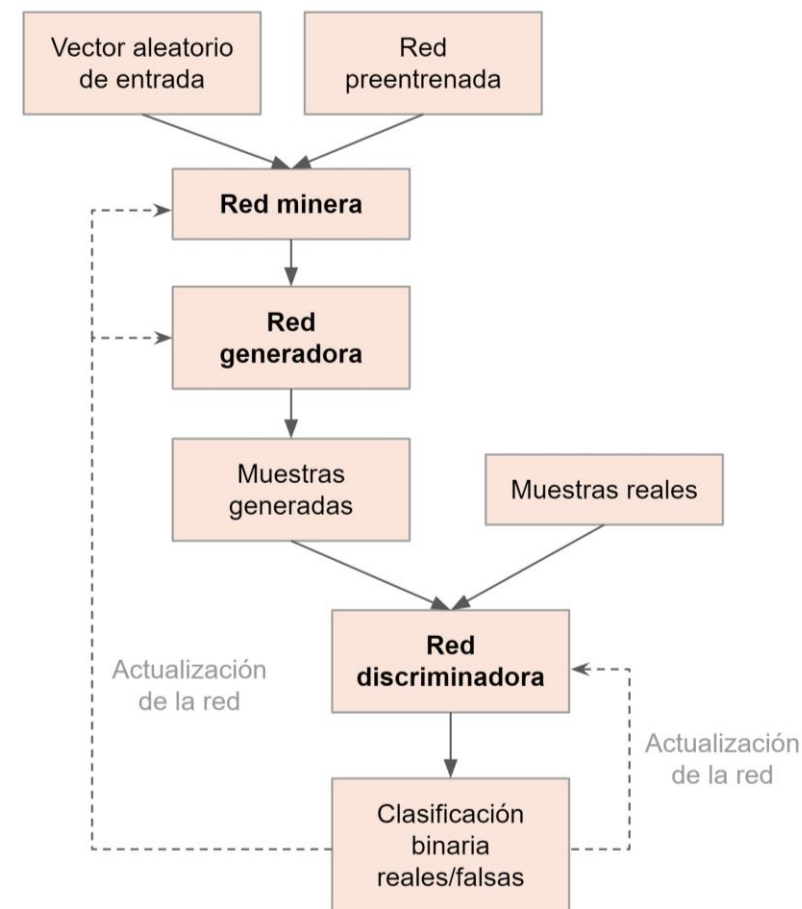
- Transferencia de conocimiento y ajuste fino

## BigGAN+TC+AD

- Transferencia de conocimiento y ajuste fino
- Aumento de datos

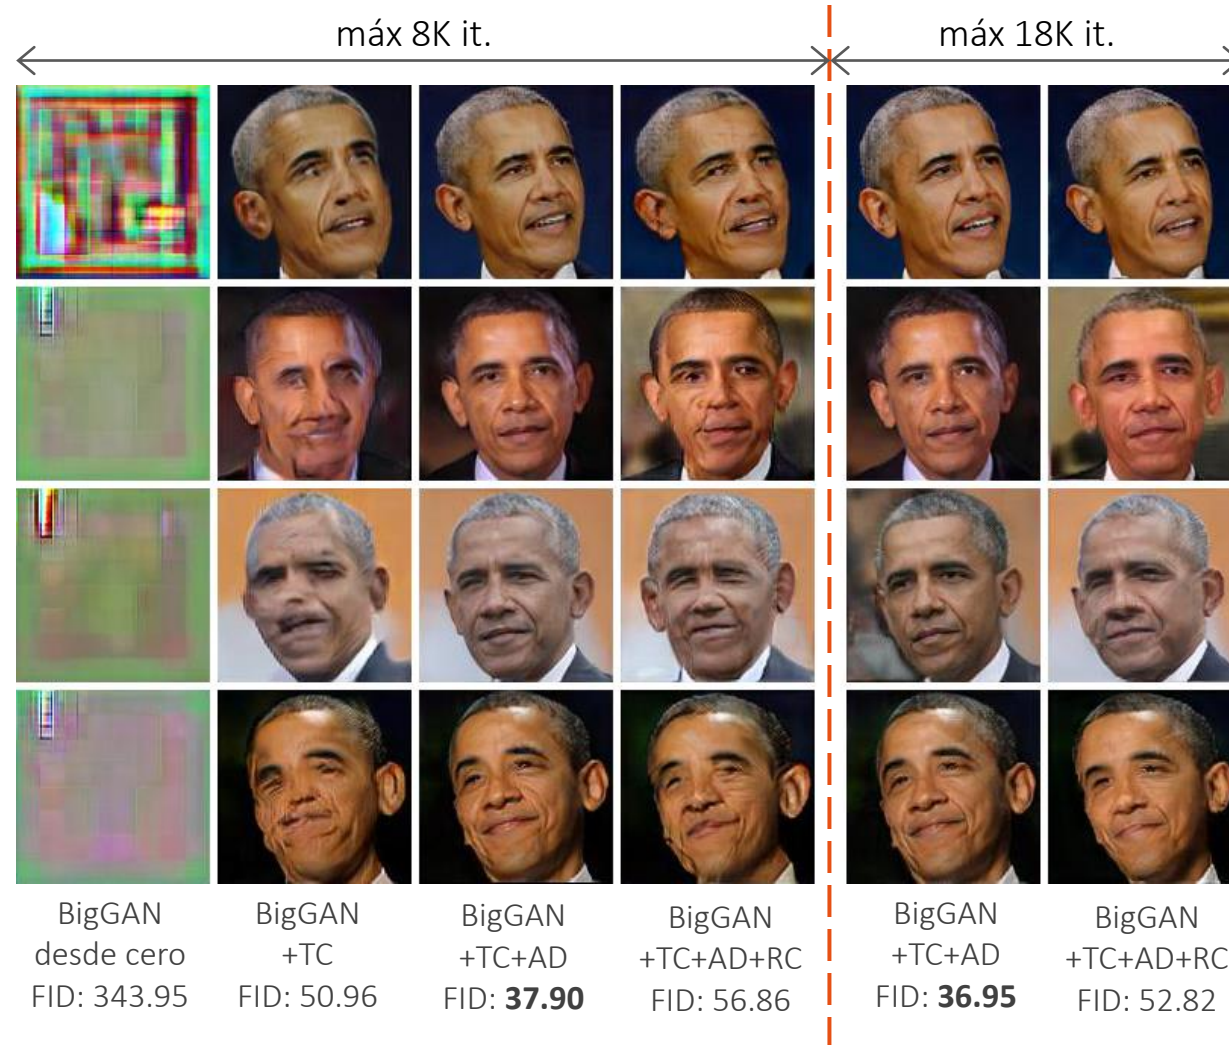
## BigGAN+TC+AD+RC

- Transferencia de conocimiento y ajuste fino
- Aumento de datos
- Regularización de consistencia




Modelo BigGAN+TC+AC+RC

# Resultados dataset 100-Obama



# Resultados dataset 1000-LSUN

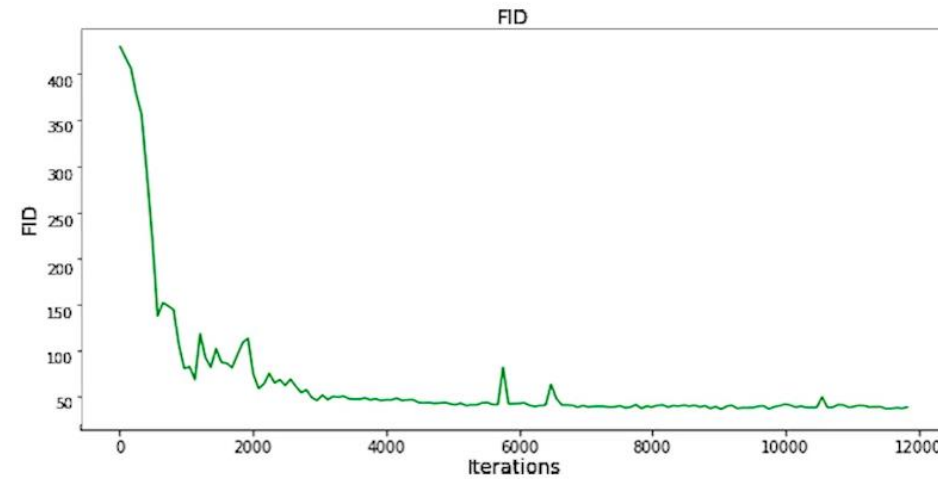
---



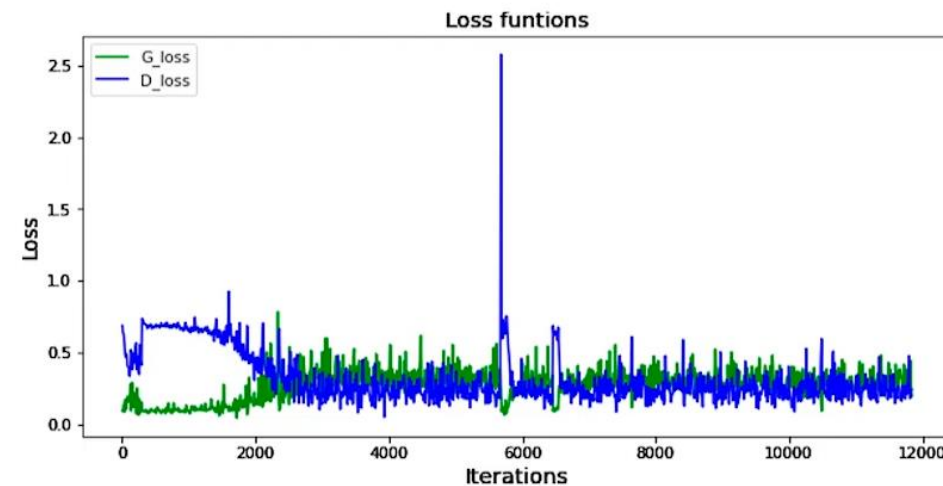
Modelo BigGAN+TC+AD. 150 épocas. FID: 78.43



# Entrenamiento modelo BigGAN+TC+AD



ITERATION:  
12000



BROCK, A. ET AL. BIGGAN  
ARXIV:1809.11096 (2018)

WANG, Y. ET AL. MINEGAN  
ARXIV:1912.05270 (2019)

ZHAO, S. ET AL. DIFFAUGMENT  
ARXIV:2006.10738 (2020)



1. INTRODUCCIÓN
2. OBJETIVOS
3. ESTADO DEL ARTE
4. MÉTODOS
5. RESULTADOS
- 6. CONCLUSIONES**
7. LÍNEAS FUTURAS

# Conclusiones

---

- El uso de la técnica de transferencia de conocimiento y ajuste fino es una poderosa herramienta que aumenta notablemente la eficiencia de los modelos.
- La técnica de transferencia de conocimiento es más eficiente cuanto más similar sea el dominio del *dataset* con el de las redes preentrenadas.
- La aplicación de la técnica de transferencia de conocimiento y ajuste fino junto a las técnicas de aumento de datos y regularización de consistencia mejora la eficiencia de los modelos.
- La técnica de regularización de consistencia requiere mayor poder de computación.
- La eficiencia de las redes generativas está muy condicionada por la cantidad y variabilidad de las muestras del *dataset*.
- A pesar de las mejoras, siguen existiendo problemas comunes de las GANs.

1. INTRODUCCIÓN
2. OBJETIVOS
3. ESTADO DEL ARTE
4. MÉTODOS
5. RESULTADOS
6. CONCLUSIONES
- 7. LÍNEAS FUTURAS**

# Investigaciones futuras

---

- Investigación sobre el umbral de truncamiento de la arquitectura BigGAN.
- Aplicación del modelo de transferencia de conocimiento Freeze-D.
- Aplicación de transformaciones más diversas y del modelo ADA para mejorar la técnica de aumento de datos.
- Aplicación del modelo de regularización de consistencia de SimCLR.
- Estudiar distintas arquitecturas GAN, como StyleGAN2.
- Investigación sobre Transformers y del método TransGAN.
- Posibilidad de publicar un artículo que condense la investigación realizada en este TFM.

# ¡GRACIAS!

**Alumno:** Javier Martí Isasi

**Director:** Dr. Félix José Fuentes Hurtado